센서 맥락 기반 정책과 명령 검증을 결합한 로컬 LLM 기반 IoT 제어 시스템의 구현 및 평가

김석현
영남대학교 전자공학과

22211897@yu.ac.kr

Implementation and Evaluation of a Local LLM-Based IoT Control System with Sensor-Context-Based Policy and Command Validation

Seokhyeon Kim
Department of Electronic Engineering, College of Digital Convergence, Yeungnam University

요 약

본 논문은 영어 음성 또는 텍스트 요청을 로컬 LLM 으로 해석하고, 센서 맥락 기반 정책과 명령 검증을 거쳐 가정 내 기기를 제어하는 시스템을 구현하고 평가한다. MacBook Air M1 8 GB 에서 faster-whisper tiny.en 과 Ollama llama3.2:3b 를 실행하였다. 요구사항 기반 고정 평가 세트 40 건에서 Full Pipeline 의 명령 정확 일치율은 92.5%로 LLM Only 의 20.0% 와 Rules Only 의 77.5%보다 높았다. 구현 코드를 고정한 뒤 결과 관측 전에 확정한 신규 표현 20 건에서는 65.0%를 기록하였다. 웹 수집 3 명의 음성 녹음 108 개에서 단어 오류율은 14.0%, 음성 입력으로 생성한 명령의 정확 일치율은 75.9%였다. 고정 음성 파일을 이용한 커튼 시험에서는 커튼의 최종 Home Assistant 상태가 6 회 모두 기대 상태와 일치하였다. 고정 LLM 출력의 사후 분석에서 정규화와 장치 및 동작 허용목록을 제거하면 정확 일치 건수가 감소하였다.

Ⅰ. 서 론

LLM 기반 스마트홈 제어는 자연어 요청을 장치 동작으로 변환한다[1]. 기존 연구는 자원 제약 장치에서 Home Assistant 용 LLM 의 의도 및 슬롯 탐지와 JSON 동작 생성을 평가하였다[2]. 구조화 출력 기법은 JSON Schema 와 같은 형식 제약을 적용할 수 있지만[3], 실제 환경에서 올바른 장치와 동작을 실행하는지는 별도의 의미적 검증이 필요하다. 시스템 개발 과정에서 모델이 연결되지 않은 장치와 지원하지 않는 동작을 제안하는 사례가 관찰되어, 모델 출력과 Home Assistant 실행 사이에 결정론적 정책과 명령 검증 계층을 배치하였다.

본 논문의 기여는 세 가지다. 첫째, 로컬 STT 와 LLM, 요청 시점 센서 맥락, 결정론적 정책과 장치별 검증을 Home Assistant 실행 경로로 연결하였다. 둘째, 네 구성에서 명령 계획의 정확 일치율을 고정 요구사항과 사전 고정 신규 표현에서 비교하였다. 셋째, 고정 음성 입력부터 커튼의 최종 Home Assistant 상태까지의 경로를 검증하고, 현장 센서 조건에서의 동작과 미지원 요청의 Home Assistant 호출 차단을 확인하였다. 대상은 한 가정의 커튼과 단방향 IR 에어컨 프리셋이며 영어 명령만 평가하였다.

Ⅱ. 시스템 및 평가 방법

음성 입력은 faster-whisper 의 tiny.en 으로 변환한다. 텍스트와 음성은 FastAPI 처리 경로를 공유한다. 요청 시작 시 Home Assistant /api/states 를 한 번 조회하여 온도, 습도, 조도와 커튼 상태로 맥락을 구성하고 사용자 요청 및 제어 가능한 논리 장치와 함께 Ollama 에 전달한다. LLM 은 llama3.2:3b Q4_K_M 이며 temperature 는 0.0 이다.



그림 1. 본 논문에서 평가한 제어 경로. HA 센서 및 커튼 상태는 LLM 입력과 상태 정책에 사용된다.

모델 응답을 JSON 으로 파싱한 뒤 명령 정규화, 상태 정책, 실제 배치 장치 및 지원 동작의 허용목록과 JSON Schema 검사를 적용한다. 고온 28 °C 초과, 어두움 100 lx 미만, 밝음 800 lx 초과는 평가에 고정한 정책값이며 쾌적성 기준이 아니다. 현장 저조도 관찰값 235 lx 가 기존 100 lx 어두움 조건에 해당하지 않아, 기존 평가 기준은 유지한 채 기능 시험에 별도 임시 300 lx 현장 적용 프로파일을 사용하였다.

요구사항 기반 평가 세트는 동작 필요 22 건과 무동작 18 건으로 구성된 40 건이다. 각 사례는 사용자 요청, 사전에 고정한 합성 맥락과 정답 명령으로 구성하였다. LLM Only 와 LLM + Context 는 동일 모델과 장치 범위를 사용하고 맥락 제공 여부만 다르며, JSON 파싱 후 결정론적 후처리를 적용하지 않는다. Rules Only 는 영화, 외출, 일부 냉방 요청과 명시적 기기 동작을 키워드 및 정규식으로 해석하는 규칙 기반 파서에 동일한 정규화, 상태 정책, 허용목록 및 스키마 검사를 적용한다. Full Pipeline 은 맥락을 제공한 LLM 의 출력에 동일한 결정론적 후처리를 적용한다. 명령 정확 일치는 (entity_id, action, value)의 중복을 보존한 다중집합을 순서와 관계없이 비교해 판정하였다. 동일 설정의 전체 평가는 5 회 반복하였고, 평가 대상 구현 코드를 고정한 뒤 결과 관측 전에 확정한 신규 표현 20 건은 별도로 1 회 평가하였다.

두 평가 세트의 Full Pipeline 첫 실행에서 보존한 LLM 출력을 고정해 후처리 네 단계의 순차 적용과 개별 제거를 사후 재생하였다. 새 추론이나 장치 전송 없이 최종 출력 60 건과 기존 점수를 재현하였다. 허용목록 제거는 해당 후처리 함수만 제외하며, 프롬프트와 정규화의 장치 정보는 유지한다.

음성 평가는 고정된 영어 문장 12 개를 화자당 3 회씩 녹음하고 각 문장에 원본 명령 사례와 동일한 합성 맥락을 적용하였다. MacBook 내장 마이크 수집에서는 1 명이 36 개를 녹음했고, 웹 수집에서는 다른 3 명이 108 개를 제출하였다. 동일한 STT, LLM 및 정답 명령을 사용했으며 웹 수집 3 명의 녹음 장치와 실내 환경은 통제하지 않았다. 웹 수집 파일은 모두 평가에 포함됐고 음성 경로는 실제 장치에 명령을 전송하지 않았다. 명령 계획 시간은 6 회 예열한 뒤 대표 6 건을 순환하며 총 30 회 측정한 로컬 Ollama HTTP 호출 및 후처리 시간으로, STT, Home Assistant 상태 수집과 제어 호출, 물리 동작을 제외하였다. 커튼 열기와 닫기 각 3 회는 매 시험 전 반대 초기 상태를 Home Assistant 에서 확인한 뒤 고정 WebM 파일로 실행하였다. 별도로 밝음과 300 lx 현장 적용 프로파일의 어두움 조건에서 동작 및 무동작 쌍을 실행하고, 미지원 요청 두 건의 Home Assistant 호출 여부를 확인하였다.

Ⅲ. 결 과

표 1 에서 Full Pipeline 은 두 평가 세트에서 네 조건 중 가장 높은 명령 정확 일치율을 기록하였다. 요구사항 평가에서 동작 필요 20/22 와 무동작 17/18 에서 명령이 정확히 일치했고, 동일 설정의 5 회 반복에서도 37/40 과 사례별 결과가 유지되었다. Rules Only 대비 7 건이 오답에서 정답으로, 1 건이 정답에서 오답으로 바뀌어 정확 일치가 순 6 건 증가하였다. LLM + Context 가 LLM Only 보다 높지 않았으므로 맥락을 프롬프트에 추가하는 것만으로 성능이 개선됐다고 해석할 수 없다. 신규 표현 평가의 Full Pipeline 은 동작 필요 8/13 과 무동작 5/7, 전체 13/20 으로 새로운 표현에 대한 일반화 한계를 보였다.

표 1. 명령 계획의 정확 일치율

조건	요구사항 40 건	신규 표현 20 건
LLM Only	8/40 (20.0%)	6/20 (30.0%)
LLM + Context	8/40 (20.0%)	5/20 (25.0%)
Rules Only	31/40 (77.5%)	10/20 (50.0%)
Full Pipeline	**37/40 (92.5%)**	**13/20 (65.0%)**

표 2. 고정 LLM 출력의 단계 제거 사후 분석

제외한 단계	요구사항 40 건	신규 표현 20 건
없음	**37/40**	**13/20**
정규화	23/40	12/20
상태 정책	37/40	13/20
허용목록	30/40	7/20
스키마 검사	37/40	13/20

표 2 는 다른 단계를 유지한 제거 조건별 결과다. 순차 적용에서는 정규화 후 30/40 과 7/20, 허용목록 후 37/40 과 13/20 이었다. 상태 정책과 스키마 검사 제거는 이 표본의 정확 일치 건수를 바꾸지 않았다. 두 단계의 일반적 효용을 판단할 수 없으며, 단계 간 상호작용과 독립적 기여를 분리하지 않는다.

웹 수집 3 화자의 음성 입력에 대한 명령 정확 일치율은 동작 필요 64/90(71.1%), 무동작 18/18(100.0%)이었다. 화자별 단어 오류율은 5.1~26.4%, 명령 정확 일치율은 58.3~88.9%였다. 웹 수집 오답 26 건 중 커튼 중지 요청 9 건은 기준 텍스트를 입력해도 명령 계획이 실패했으므로 음성 인식 오류만으로 설명되지 않는다. 내장 마이크 수집과 웹 수집은 녹음 경로가 달라 결과를 별도로 보고한다. 표 3 의 명령 계획 시간과 커튼 상태 정착 시간은 측정 범위가 다르므로 합산하거나 직접 비교하지 않는다.

표 3. 음성, 소프트웨어 및 현장 검증 결과

지표	결과
내장 마이크(1 명) 단어 오류율	22/216 (10.2%)
내장 마이크(1 명) 명령 정확 일치율	30/36 (83.3%)
웹 수집(3 명) 단어 오류율	91/648 (14.0%)
웹 수집(3 명) 명령 정확 일치율	82/108 (75.9%)
평균 명령 계획 시간	3.22 s
커튼 최종 HA 상태 일치	6/6
현장 밝음 조건	2/2
현장 어두움(300 lx 프로파일)	2/2
미지원 요청 차단	2/2

커튼 상태 정착 시간은 평균 20.9 s, 범위 19.0~26.3 s 였다. 이는 고정 음성 파일부터 최종 Home Assistant 상태 확인까지의 현장 시험 결과이며 외부 카메라로 측정한 물리 완료 시간은 아니다. 밝음 조건과 별도 300 lx 현장 적용 프로파일의 어두움 조건에서 동작 및 무동작 쌍이 각각 2/2 일치하였다. fan-speed 와 정의되지 않은 scene 요청 두 건은 Home Assistant 호출 없이 차단되었다. IR 에어컨은 Cool 24 와 Off 의 물리 반응을 관찰했지만 양방향 상태 피드백이 없어 신뢰도나 상태 정확도로 해석하지 않았다.

Ⅳ. 결 론

Full Pipeline 은 고정 요구사항과 사전 고정 신규 표현 평가 모두에서 다른 세 비교 조건보다 높은 명령 계획의 정확 일치율을 보였다. 사후 분석에서 정규화 또는 장치 및 동작 허용목록을 제거하면 정확 일치 건수가 감소했다. 반면 맥락을 LLM 입력에 추가하는 것만으로는 개선되지 않았고, 신규 표현에서 정확 일치율이 감소하여 현재 명령 해석과 정책의 표현 일반화에 한계가 있음을 확인하였다.

웹 수집 3 화자 음성 평가에서는 명령 정확 일치율의 화자 간 차이가 관찰됐으나 마이크와 녹음 환경이 통제되지 않아 원인을 특정할 수 없다. 결과는 소규모 편의 표본, 개발자 작성 명령 세트, 단일 주택과 두 장치 유형에 한정되며, IR 에어컨의 양방향 상태 피드백도 없다. 후속 연구에서는 외부 작성 명령 세트, 통제된 다화자 및 소음 조건과 반복 IR 제어를 평가한다.

참 고 문 헌

[1] C. Yu et al., “Leveraging LLMs for Efficient and Personalized Smart Home Automation,” arXiv:2601.04680, 2026. https://doi.org/10.48550/arXiv.2601.04680

[2] R. Birkmose, N. M. Reece, E. H. Norvin, J. Bjerva, and M. Zhang, “On-Device LLMs for Home Assistant: Dual Role in Intent Detection and Response Generation,” Proc. WNUT, pp. 57–67, 2025. https://doi.org/10.18653/v1/2025.wnut-1.7

[3] S. Geng et al., “JSONSchemaBench: A Rigorous Benchmark of Structured Outputs for Language Models,” arXiv:2501.10868v3, 2025. https://doi.org/10.48550/arXiv.2501.10868